

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR



Estudio de caso

“Cuantización Y Propagación Del Error En Traducción En Tiempo Real”

Integrantes:

Benjamín Flores Alegría

Williams Campos Corvalan

Mauricio Castro Leal

Universidad Católica del Maule

Ingeniería Civil Informática

INF-321 – Computación Numérica

Docente: Sergio Hernández

26 de agosto de 2026

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Índice

ÍNDICE.....	2
1. INTRODUCCIÓN Y PLANTEAMIENTO DEL PROBLEMA NUMÉRICO	3
2. REPRESENTACIÓN NUMÉRICA Y CUANTIZACIÓN	3
3. DISEÑO EXPERIMENTAL Y RESULTADOS	5
4. PROPAGACIÓN DEL ERROR EN LA CASCADA ASR → LLM	7
5. CONCLUSIONES Y RECOMENDACIÓN TÉCNICA	8
6.1 CONCLUSIÓN PRINCIPAL	8
6.2 RECOMENDACIÓN TÉCNICA	8
6. ANEXOS.....	9
ANEXO A. CONFIGURACIÓN EXPERIMENTAL Y REPRODUCIBILIDAD	9
ANEXO B. CORPUS Y REFERENCIAS	10
ANEXO C. RESULTADOS DETALLADOS DEL ASR.....	12
ANEXO D. ERROR NUMÉRICO Y CUANTIZACIÓN	14
ANEXO E. TAMAÑO Y MEMORIA DE LOS MODELOS	15
ANEXO F. RESULTADOS COMPLETOS DE TRADUCCIÓN	15
ANEXO G. PROPAGACIÓN ASR → LLM POR AUDIO	16
ANEXO H. EJEMPLOS DE ERRORES SEMÁNTICAMENTE RELEVANTES.....	17
ANEXO I. ARCHIVOS Y SCRIPTS ENTREGADOS	18

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

1. Introducción y planteamiento del problema numérico

En este trabajo analizamos el efecto de reducir la precisión numérica de los modelos utilizados en una cascada local de reconocimiento de voz y traducción. Consideramos como escenario un centro de atención de urgencia que necesita comunicarse con pacientes que no hablan español, por lo que planteamos realizar todo el procesamiento localmente mediante whisper.cpp y Ollama.

Nuestro problema numérico consiste en estudiar cómo la reducción de bits utilizados para representar los pesos afecta la memoria, latencia y calidad final. Buscamos determinar qué formato ofrece el mejor compromiso entre estos factores, manteniendo además un factor de tiempo real ($RTF < 1$).

El flujo evaluado se muestra en la Figura 1. A partir de los resultados buscamos responder cuánto podemos reducir la precisión antes de observar una degradación relevante en la transcripción o traducción.




Figura 1. Flujo de procesamiento de la cascada ASR → LLM.

A través de los cálculos y análisis desarrollados buscamos responder la pregunta central del estudio: **¿cuánta precisión numérica podemos sacrificar antes de observar una degradación relevante en la transcripción y traducción?** A partir de los resultados analizamos hasta qué nivel de cuantización podemos reducir los recursos manteniendo una calidad similar a las configuraciones de mayor precisión.

En nuestro análisis evaluamos la calidad mediante los errores de transcripción y la similitud de las traducciones respecto de sus referencias. Además, prestamos especial atención a errores capaces de modificar el sentido del mensaje. Estas métricas permiten comparar los formatos estudiados, aunque no representan por sí solas una validación clínica del sistema.

2. Representación numérica y cuantización

Para estudiar el efecto de disminuir la precisión es necesario distinguir entre la representación en punto flotante y la cuantización entera utilizada por GGML. En aritmética de punto flotante, el resultado de representar un número real x puede modelarse mediante:

$$fl(x) = x(1 + \delta), \quad |\delta| \leq u$$

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

donde u corresponde a la **unidad de redondeo**, es decir, una cota para el error relativo introducido al aproximar un valor al número representable más cercano. Para los formatos IEEE-754 utilizados como referencia:

$$u_{32} = 2^{-24} = 5.960 \times 10^{-8}, u_{16} = 2^{-11} = 4.883 \times 10^{-4}$$

En los formatos Q8_0, Q5_1 y Q4_0, GGML agrupa los pesos en bloques y los reconstruye mediante $\tilde{w}_i = dq_i + m$, donde:

q_i = código cuantizado, d = escala del bloque, m = desplazamiento según corresponda

, introduciendo un error de representación $\varepsilon_i = \tilde{w}_i - w_i$. Bajo redondeo al nivel más cercano se considera la cota ideal:

$$\text{Cota ideal} \rightarrow |\varepsilon_i| \leq \frac{|d|}{2}.$$

Bits efectivos por peso. Para comparar correctamente los formatos se considera también el costo amortizado de los parámetros almacenados por bloque (b/p bits por peso)

$$F_{32} = 32 \text{ b/p}, F_{16} = 16 \text{ b/p}, Q_{8_0} = 8.5 \text{ b/p}, Q_{5_1} = 6.0 \text{ b/p}, Q_{4_0} = 4.5 \text{ b/p}$$

Verificación experimental. Para cuantificar el error introducido se utilizó el error absoluto medio:

$$MAE = \frac{1}{N} \sum_{i=1}^N |\tilde{w}_i - w_i|$$

Formato	MAE absoluto	Error relativo mediano	$ \varepsilon_i \leq \frac{ d }{2}$
F16	0	0%	No aplica
Q8_0	1.182×10^{-4}	0.6382 %	99.34 %
Q5_1	7.227×10^{-4}	3.986 %	99.76 %
Q4_0	1.870×10^{-3}	10.30 %	99.71 %

Tabla 1. Verificación experimental del error de representación de los pesos.

Como observamos en la Tabla 1, el error de representación aumenta al reducir la cantidad de bits por peso. Q8_0 presentó el menor MAE entre los formatos cuantizados, mientras que Q4_0 presentó el mayor. Además, en los tres formatos cuantizados más del 99 % de los pesos evaluados cumplió la cota ideal de medio paso.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Estos resultados muestran que reducir la precisión aumenta el error numérico de los pesos, aunque esto no implica necesariamente una degradación proporcional en la transcripción o traducción, aspecto que analizamos en las secciones siguientes.

El caso particular de F16 se detalla en el Anexo D.

3. Diseño experimental y resultados

Ejecutamos los experimentos de forma completamente local en un MacBook Air M1 2020 con 8 GB de memoria unificada, CPU Apple M1 de 8 núcleos y GPU integrada. Para el reconocimiento de voz utilizamos `whisper.cpp v1.9.2`, commit `592feef04a1802b18cbeffd0fd0eb5d02570c2ec`, evaluando F32, F16, Q8_0, Q5_1 y Q4_0 sobre Whisper Base. La traducción se realizó mediante Ollama 0.32.2 utilizando Gemma 1B en Q8_0 y Q4_K_M. La configuración completa se incluye en el Anexo A.

Utilizamos un corpus de 10 audios en inglés, con duraciones entre 15 y 30 s y una duración total de 212.3 s. Cada audio contó con una transcripción y traducción de referencia, y ejecutamos cada formato de Whisper cinco veces manteniendo constantes los principales parámetros de decodificación. Las transcripciones y traducciones de referencia, junto con la descripción del corpus, se incluyen en el **Anexo B**.

Evaluamos la transcripción mediante WER y CER, la traducción mediante chrF y el rendimiento mediante RTF, memoria RAM y tamaño del modelo. WER y CER miden el error respecto de la transcripción de referencia, chrF la similitud con la traducción de referencia y $RTF < 1$ indica procesamiento más rápido que el tiempo real.

La Tabla 2 compara el costo de representación, memoria y rendimiento de los cinco formatos; el tamaño se expresa en MB, la memoria pico en MiB y d corresponde a la mediana del paso de cuantización.

Formato	Bits/peso	Disco (MB)	RAM(MiB)	d mediano	WER (%)	CER (%)	chrF	RTF
F32	32.0	290.96	526.38	No aplica	9.950	4.432	80.898	0.0392
F16	16.0	147.95	341.94	No aplica	9.950	4.432	80.898	0.0307
Q8_0	8.5	81.77	255.70	4.501×10^{-4}	11.443	5.164	80.604	0.0294
Q5_1	6.0	59.71	227.42	2.899×10^{-3}	12.687	5.594	80.437	0.0306
Q4_0	4.5	46.47	208.91	7.145×10^{-3}	12.935	5.766	78.671	0.0285

Tabla 2. Recursos y rendimiento según formato de Whisper.

Como observamos en la Tabla 2, todos los formatos cumplieron $RTF < 1$. F16 mantuvo el desempeño de F32 con menor tamaño y memoria, mientras que los formatos cuantizados permitieron

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

mayores reducciones de recursos con una degradación progresiva. Entre ellos, Q8_0 mantuvo el desempeño más cercano a las configuraciones de mayor precisión.

Precisión de la cascada según la representación numérica




Figura 2. Efecto de la cuantización de Whisper sobre WER y chrF.

Como observamos en la Figura 2, F32 y F16 presentaron el mismo desempeño. Al reducir la precisión aumentó el WER, mientras chrF se mantuvo relativamente estable hasta Q5_1 y presentó su mayor caída en Q4_0. Respecto de F32, Q8_0 aumentó el WER en 1.493 puntos porcentuales (15.0 % relativo), mientras chrF disminuyó solo 0.294 puntos (0.363 %), mostrando que ambas métricas no se degradan de forma proporcional.




Figura 3. Error absoluto medio de los pesos según el formato de representación.

Como observamos en la Figura 3, el MAE aumentó desde 1.182×10^{-4} en Q8_0 hasta 1.870×10^{-3} en Q4_0, sin producir una disminución proporcional de chrF. En recursos, Q8_0 redujo la memoria pico desde 526.38 hasta 255.70 MiB (51.4 %), manteniendo $RTF < 1$, mientras Q4_0 alcanzó 208.91 MiB a costa de una mayor pérdida de traducción.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

4. Propagación del error en la cascada ASR → LLM

Para analizar la propagación del error comparamos Referencia→LLM, F32→LLM y ASR cuantizado→LLM con Gemma 1B en Q8_0 y Q4_K_M. Usamos WER como error de entrada y chrF como calidad de salida, distinguiendo el error propio del LLM del asociado a una transcripción imperfecta.

Cuantización LLM	Condición experimental	E_{in} : WER (%)	chrF salida	E_{out} (puntos)	ΔE_{out} (Puntos)
Gemma3 Q8_0	Referencia → LLM	0.000	85.283	14.717	0.000
Gemma3 Q8_0	F32 → LLM	9.950	80.898	19.102	4.385
Gemma3 Q8_0	Q8_0 → LLM	11.443	80.604	19.396	4.679
Gemma3 Q8_0	Q5_1 → LLM	12.687	80.437	19.563	4.846
Gemma3 Q8_0	Q4_0 → LLM	12.935	78.671	21.329	6.612
Gemma3 Q4_K_M	Referencia → LLM	0.000	86.106	13.894	0.000
Gemma3 Q4_K_M	F32 → LLM	9.950	80.482	19.518	5.624
Gemma3 Q4_K_M	Q8_0 → LLM	11.443	81.023	18.977	5.083
Gemma3 Q4_K_M	Q5_1 → LLM	12.687	79.325	20.675	6.781
Gemma3 Q4_K_M	Q4_0 → LLM	12.935	78.044	21.956	8.062

Tabla 3. Propagación del error en la cascada ASR→LLM.

Definimos E_{in} = WER, E_{out} = $100 - chrF$ y $\Delta E_{out} = E_{out, condición} - E_{out, referencia}$ tomando Referencia→LLM como condición base para cada cuantización del LLM.

Como observamos en la Tabla 3, la mayor caída inicial aparece al incorporar la salida del ASR. Q8_0 mantuvo resultados próximos a F32, mientras que Q4_0 presentó la mayor degradación final en ambas cuantizaciones del LLM. Esto muestra que los errores de transcripción pueden propagarse hasta la traducción y que su efecto depende tanto del ASR como del LLM.




Figura 4. Evolución de chrF según la entrada ASR para las dos cuantizaciones de Gemma.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

La Figura 4 muestra una relación no monotónica entre formatos, aunque Q4_0 presenta la menor calidad final en ambas cuantizaciones del LLM.

5. Conclusiones y recomendación técnica

6.1 Conclusión principal

Los resultados muestran que reducir la precisión numérica disminuye considerablemente el tamaño de los modelos y el consumo de memoria, manteniendo tiempos de ejecución inferiores al tiempo real. F16 conservó el desempeño de F32, mientras que Q8_0 y Q5_1 permitieron mayores reducciones de recursos con una degradación limitada; Q4_0 presentó la mayor pérdida final.

Además, observamos que el aumento del error numérico de los pesos no produjo una disminución proporcional de la calidad de traducción, por lo que la relación entre precisión numérica y desempeño final no es lineal.

6.2 Recomendación técnica

Para el escenario evaluado recomendamos Q8_0 como alternativa principal, ya que presentó el mejor compromiso entre reducción de memoria, tamaño del modelo y calidad de transcripción y traducción. Mantuvo un desempeño cercano a las configuraciones de mayor precisión con un consumo considerablemente menor.

F16 es una opción más conservadora cuando se prioriza un comportamiento similar a F32, mientras que Q5_1 permite una mayor reducción de recursos a costa de un aumento más evidente del error de transcripción. En cambio, Q4_0 presentó la mayor degradación final, por lo que no lo consideramos la primera alternativa para este escenario.

Formato	Evaluación final
F32	Referencia de mayor precisión evaluada
F16	Opción conservadora
Q8_0	Mejor compromiso técnico
Q5_1	Compresión más agresiva, mayor WER
Q4_0	Mayor pérdida final, no recomendado

Tabla 4. Síntesis de la evaluación técnica de los formatos analizados.

Aun en las configuraciones de mayor precisión observamos errores capaces de modificar información semánticamente relevante. Por ello, métricas como WER y chrF no permiten evaluar por sí solas la gravedad de cada error, y nuestros resultados deben interpretarse como una recomendación técnica, no como una validación clínica definitiva.

En síntesis, la cuantización permite reducir recursos, pero a partir de cierto nivel la pérdida de calidad se vuelve más evidente. En las condiciones evaluadas, Q8_0 presentó el mejor equilibrio entre eficiencia y desempeño.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

6. Anexos

Anexo A. Configuración experimental y reproducibilidad

En este anexo presentamos la configuración utilizada durante los experimentos, incluyendo el hardware, software, modelos y principales parámetros de ejecución. Esta información permite identificar las condiciones bajo las cuales obtuvimos los resultados presentados en el informe.

Componente	Configuración
Equipo	MacBook Air M1 (2020)
CPU	Apple M1, 8 núcleos (4 de rendimiento + 4 de eficiencia)
GPU	Integrada Apple M1, 7 núcleos
Memoria	8 GB de memoria unificada
Almacenamiento	SSD 256 GB
Sistema operativo	macOS Tahoe 26.5.2
whisper.cpp	v1.9.2
Commit	592feef04a1802b18cbeffd0fd0eb5d02570c2ec
Ollama	0.32.2

Tabla A1. Hardware y software utilizados durante los experimentos.

Whisper

Parámetro	Valor
Modelo base	Whisper Base
Formatos	F32, F16, Q8_0, Q5_1, Q4_0
Idioma	en
Threads	4
Beam size	5
Best-of	5
Temperatura	0
Repeticiones	5 por formato

LLM

Modelo	Cuantización
gemma3:1b-it-q8_0	Q8_0
gemma3:1b	Q4_K_M

Parámetro	Valor
Temperatura	0
Seed	42
Stream	False

Tabla A2. Modelos y parámetros de ejecución

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Anexo B. Corpus y referencias

En este anexo presentamos los audios utilizados en el experimento junto con su duración y cantidad de palabras de referencia.

Audio	Caso	Duración (s)	Palabras de referencia
audio01	Dolor torácico	19.69	41
audio02	Alergia	16.77	37
audio03	Accidente	16.60	38
audio04	Dolor abdominal	20.78	37
audio05	Diabetes	21.87	43
audio06	Fiebre	21.25	38
audio07	Respiración	22.66	40
audio08	Herida	22.61	43
audio09	Mareo	23.96	41
audio10	Dolor de cabeza	26.11	44
Total	10 audios	212.288	402

Tabla B1. Descripción del corpus utilizado.

Audio	Referencia en inglés	Referencia en español
audio01	The patient reports severe chest pain that started about thirty minutes ago. The pain becomes stronger when he takes a deep breath, and he also feels short of breath. He has no known allergies and has not taken any medication today.	El paciente reporta un dolor intenso en el pecho que comenzó hace unos treinta minutos. El dolor aumenta cuando respira profundamente y también siente dificultad para respirar. No tiene alergias conocidas y no ha tomado ningún medicamento hoy.
audio02	The patient is allergic to penicillin and should not receive any medication containing it. She developed a severe skin rash after taking penicillin several years ago. She currently has	La paciente es alérgica a la penicilina y no debe recibir ningún medicamento que la contenga. Desarrolló una erupción cutánea grave después de tomar penicilina hace varios años. Actualmente

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

	a fever, a sore throat, and difficulty swallowing.	tiene fiebre, dolor de garganta y dificultad para tragar.
audio03	The patient fell from a bicycle approximately one hour ago and injured his left arm. He can move his fingers, but he feels severe pain near the wrist. There is visible swelling, but there is no active bleeding.	El paciente se cayó de una bicicleta hace aproximadamente una hora y se lesionó el brazo izquierdo. Puede mover los dedos, pero siente un dolor intenso cerca de la muñeca. Hay una hinchazón visible, pero no hay sangrado activo.
audio04	The patient has had abdominal pain since yesterday evening. The pain is mainly located on the lower right side and has gradually become stronger. She also reports nausea and loss of appetite, but she has not vomited.	La paciente ha tenido dolor abdominal desde ayer por la tarde. El dolor se localiza principalmente en la parte inferior derecha y ha aumentado gradualmente. También reporta náuseas y pérdida del apetito, pero no ha vomitado.
audio05	The patient has type two diabetes and normally takes medication every morning. Today he forgot to take his medicine and began feeling dizzy and weak during the afternoon. He is conscious and able to speak, but he says his condition is getting worse.	El paciente tiene diabetes tipo dos y normalmente toma medicamentos todas las mañanas. Hoy olvidó tomar su medicamento y comenzó a sentirse mareado y débil durante la tarde. Está consciente y puede hablar, pero dice que su condición está empeorando.
audio06	The patient has had a high fever since last night and has been feeling extremely tired. She also reports muscle pain, chills, and a persistent headache. She has been drinking water regularly and has not taken any antibiotics.	La paciente ha tenido fiebre alta desde anoche y se ha sentido extremadamente cansada. También reporta dolor muscular, escalofríos y un dolor de cabeza persistente. Ha estado bebiendo agua regularmente y no ha tomado ningún antibiótico.
audio07	The patient has difficulty breathing when walking short distances and sometimes feels pressure in his chest. These symptoms began two days ago and have gradually become worse. He has a history of asthma but has not used his inhaler today.	El paciente tiene dificultad para respirar al caminar distancias cortas y a veces siente presión en el pecho. Estos síntomas comenzaron hace dos días y han empeorado gradualmente. Tiene antecedentes de asma, pero hoy no ha utilizado su inhalador.
audio08	The patient cut her right hand while preparing food approximately forty minutes ago. The wound is still bleeding slightly, but she can move all of her fingers normally. She reports moderate pain and does not remember when she received her last tetanus vaccine.	La paciente se cortó la mano derecha mientras preparaba comida hace aproximadamente cuarenta minutos. La herida todavía sangra levemente, pero puede mover todos los dedos con normalidad. Reporta dolor moderado y no recuerda cuándo recibió su última vacuna contra el tétanos.
audio09	The patient suddenly became dizzy while standing at work this morning. He did not lose	El paciente se mareó repentinamente mientras estaba de pie en el trabajo esta mañana. No perdió

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

	consciousness, but he felt weak and had to sit down immediately. He has eaten very little today and says that similar symptoms happened once last month.	el conocimiento, pero se sintió débil y tuvo que sentarse inmediatamente. Ha comido muy poco hoy y dice que síntomas similares ocurrieron una vez el mes pasado.
audio10	The patient has experienced a strong headache for approximately three hours. The pain is mainly located behind her eyes and becomes worse when she looks at bright lights. She also feels slightly nauseous but has no problems speaking or moving her arms and legs.	La paciente ha experimentado un fuerte dolor de cabeza durante aproximadamente tres horas. El dolor se localiza principalmente detrás de los ojos y empeora cuando mira luces brillantes. También siente leves náuseas, pero no tiene problemas para hablar ni para mover los brazos y las piernas.

Tabla B2. Transcripciones y traducciones de referencia del corpus.

Fuente de los audios: grabación propia y consentimiento de los participantes.

Anexo C. Resultados detallados del ASR

En esta tabla presentamos los resultados de transcripción obtenidos para cada audio y formato de Whisper. Para cada combinación reportamos WER, CER y RTF promedio.

Formato	Audio	WER (%)	CER (%)	RTF medio
F32	audio01	12.195	7.456	0.0430
F32	audio02	8.108	1.304	0.0511
F32	audio03	5.263	1.463	0.0466
F32	audio04	2.703	0.472	0.0370
F32	audio05	13.953	6.939	0.0379
F32	audio06	13.158	5.909	0.0380
F32	audio07	7.500	2.553	0.0366
F32	audio08	6.977	4.297	0.0381
F32	audio09	19.512	8.936	0.0357
F32	audio10	9.091	4.264	0.0339
F16	audio01	12.195	7.456	0.0321
F16	audio02	8.108	1.304	0.0401
F16	audio03	5.263	1.463	0.0354
F16	audio08	6.977	4.297	0.0302
F16	audio09	19.512	8.936	0.0281
F16	audio10	9.091	4.264	0.0264
Q8_0	audio01	12.195	7.456	0.0302
Q8_0	audio02	8.108	1.304	0.0392
Q8_0	audio03	5.263	1.463	0.0350
Q8_0	audio04	5.405	1.887	0.0267
Q8_0	audio05	13.953	6.939	0.0288
Q8_0	audio06	13.158	5.909	0.0282
Q8_0	audio07	15.000	5.957	0.0287
Q8_0	audio08	4.651	3.125	0.0298
Q8_0	audio09	26.829	12.766	0.0271
Q8_0	audio10	9.091	4.264	0.0245
Q5_1	audio01	12.195	7.456	0.0319

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

F16	audio04	2.703	0.472	0.0297	Q5_1	audio02	10.811	4.348	0.0391
F16	audio05	13.953	6.939	0.0309	Q5_1	audio03	5.263	1.463	0.0362
F16	audio06	13.158	5.909	0.0301	Q5_1	audio04	2.703	0.472	0.0294
F16	audio07	7.500	2.553	0.0286	Q5_1	audio05	25.581	9.388	0.0315
					Q5_1	audio06	15.789	6.364	0.0299

Q5_1	audio07	10.000	4.255	0.0283
Q5_1	audio08	6.977	4.297	0.0296
Q5_1	audio09	26.829	14.468	0.0280
Q5_1	audio10	9.091	2.713	0.0266
Q4_0	audio01	9.756	5.702	0.0307
Q4_0	audio02	16.216	8.261	0.0361
Q4_0	audio03	7.895	3.415	0.0324
Q4_0	audio04	5.405	1.415	0.0277
Q4_0	audio05	25.581	9.388	0.0298
Q4_0	audio06	13.158	6.818	0.0272
Q4_0	audio07	7.500	3.404	0.0257
Q4_0	audio08	6.977	4.297	0.0273
Q4_0	audio09	26.829	11.915	0.0264
Q4_0	audio10	9.091	2.713	0.0253

Tabla C1. Resultados ASR por audio y formato.

A partir de los resultados anteriores resumimos el comportamiento global de cada formato mediante sus métricas promedio, con el fin de respaldar los valores presentados en el cuerpo principal del informe.

Formato	WER corpus (%)	CER corpus (%)	RTF medio	SD RTF
F32	9.950	4.432	0.0392	0.0010
F16	9.950	4.432	0.0307	0.0005
Q8_0	11.443	5.164	0.0294	0.0005

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Q5_1	12.687	5.594	0.0306	0.0003
Q4_0	12.935	5.766	0.0285	0.0003

Tabla C2. Resumen estadístico por formato.

Anexo D. Error numérico y cuantización

En este anexo presentamos las estadísticas del paso de cuantización d y los errores obtenidos al comparar los pesos reconstruidos con la referencia F32.

Formato	$d_{\min}$	d_{medio}	d_{mediano}	$d_{\max}$
Q8_0	1.484×10^{-5}	4.932×10^{-4}	4.501×10^{-4}	7.675×10^{-3}
Q5_1	1.105×10^{-4}	3.121×10^{-3}	2.899×10^{-3}	3.354×10^{-2}
Q4_0	2.356×10^{-4}	7.830×10^{-3}	7.145×10^{-3}	1.218×10^{-1}

Tabla D1. Estadísticas del paso de cuantización den los bloques cuantizados de Whisper Base.

Se analizaron 97 tensores cuantizados, correspondientes a 2.206.096 bloques y 70.595.072 pesos. Para Q4_0 se utilizó $|d|$, debido a que la escala puede almacenarse con signo.

Formato	MAE	Error abs. mediano	Error abs. máximo	RMSE	Error rel. mediano	Cumplimiento $d/2$
F16	0	0	0	0	0 %	N/A
Q8_0	1.182×10^{-4}	1.040×10^{-4}	3.830×10^{-3}	1.510×10^{-4}	0.638 %	99.34 %
Q5_1	7.227×10^{-4}	6.371×10^{-4}	1.617×10^{-2}	9.283×10^{-4}	3.986 %	99.76 %
Q4_0	1.870×10^{-3}	1.648×10^{-3}	5.707×10^{-2}	2.397×10^{-3}	10.303 %	99.71 %

Tabla D2. Error de representación de los pesos respecto de la referencia F32.

Se compararon 71.504.384 pesos por formato; para verificar la cota ideal $|\epsilon| \leq |d|/2$ se consideraron 70.595.072 pesos cuantizados.

En la comparación realizada, F16 presentó error nulo respecto de la referencia utilizada. Este resultado corresponde específicamente a los pesos y al procedimiento evaluado, y no implica que binary16 posea la misma precisión numérica que binary32. En los formatos cuantizados, más del 99.3 % de los pesos evaluados cumplió la cota ideal de medio paso.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Anexo E. Tamaño y memoria de los modelos

En este anexo detallamos el tamaño en disco y la memoria pico observada para cada representación de Whisper.

Formato	Tamaño exacto (bytes)	Disco (MB)	RAM pico (MiB)	Reducción RAM vs F32
F32	290 960 233	290.96	526.38	0.00 %
F16	147 951 465	147.95	341.94	35.04 %
Q8_0	81 768 585	81.77	255.70	51.42 %
Q5_1	59 707 625	59.71	227.42	56.80 %
Q4_0	46 471 049	46.47	208.91	60.31 %

Tabla E1. Tamaño de archivo y memoria pico observada para cada representación de Whisper. El tamaño en disco se expresa en MB y la memoria en MiB; la reducción de RAM se calcula respecto de F32.

Anexo F. Resultados completos de traducción

En este anexo presentamos la calidad de traducción obtenida para cada audio y formato de Whisper, manteniendo fijo Gemma 3 1B Q8_0.

Audio	F32	F16	Q8_0	Q5_1	Q4_0
audio01	70.293	70.293	70.293	70.293	72.756
audio02	97.048	97.048	97.048	92.890	88.535
audio03	81.027	81.027	81.027	83.470	70.235
audio04	76.421	76.421	76.421	76.421	76.627
audio05	72.525	72.525	72.525	68.887	68.887
audio06	69.534	69.534	69.534	65.535	68.802
audio07	90.417	90.417	82.628	84.924	86.962
audio08	66.086	66.086	67.990	66.086	66.086
audio09	61.909	61.909	62.896	67.842	59.517
audio10	79.267	79.267	79.845	80.594	85.665
Corpus	80.898	80.898	80.604	80.437	78.671

Tabla F1. Calidad de traducción por audio según el formato de Whisper, manteniendo fijo Gemma 3 1B Q8_0. chrF se calcula respecto de la traducción española de referencia; la fila Corpus corresponde al cálculo agregado del corpus completo y no al promedio aritmético de los diez audios.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Anexo G. Propagación ASR → LLM por audio

En este anexo presentamos los resultados por audio utilizados para obtener los valores agregados de propagación del error en la cascada ASR→LLM.

Audio	Referencia→LLM	F32→LLM	Q8→LLM	Q5→LLM	Q4→LLM
audio01	78.715	70.293	70.293	70.293	72.756
audio02	97.048	97.048	97.048	92.890	88.535
audio03	83.241	81.027	81.027	83.470	70.235
audio04	76.421	76.421	76.421	76.421	76.627
audio05	83.541	72.525	72.525	68.887	68.887
audio06	73.070	69.534	69.534	65.535	68.802
audio07	96.062	90.417	82.628	84.924	86.962
audio08	75.286	66.086	67.990	66.086	66.086
audio09	77.163	61.909	62.896	67.842	59.517
audio10	83.431	79.267	79.845	80.594	85.665
Corpus	85.283	80.898	80.604	80.437	78.671

Tabla G1. chrF por audio para Gemma 3 1B Q8_0 según la entrada proporcionada al LLM. La condición Referencia utiliza la transcripción inglesa de referencia, mientras que las demás condiciones utilizan las salidas de Whisper. La fila Corpus corresponde al cálculo agregado del corpus completo.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Audio	Referencia→LLM	F32→LLM	Q8→LLM	Q5→LLM	Q4→LLM
audio01	80.951	65.185	65.185	65.185	67.060
audio02	97.822	97.822	97.822	93.508	86.385
audio03	80.020	81.027	81.027	80.498	70.818
audio04	82.006	76.089	82.006	76.089	74.699
audio05	83.541	76.653	76.653	70.644	70.644
audio06	81.228	73.538	73.538	66.182	69.503
audio07	88.392	82.894	81.298	80.482	82.203
audio08	77.987	64.983	67.532	64.983	63.864
audio09	80.156	67.399	66.628	67.842	64.006
audio10	86.176	76.707	81.151	81.741	83.135
Corpus	86.106	80.482	81.023	79.325	78.044

Tabla G2. chrF por audio para Gemma 3 1B Q4_K_M según la entrada proporcionada al LLM. La condición Referencia utiliza la transcripción inglesa de referencia, mientras que las demás condiciones utilizan las salidas de Whisper. La fila Corpus corresponde al cálculo agregado del corpus completo.

Anexo H. Ejemplos de errores semánticamente relevantes

Además de las métricas agregadas, identificamos casos en que errores del ASR modificaron información potencialmente relevante en la traducción final.

Audio	Referencia	Transcripción ASR observada	Efecto en la traducción
audio03 — Accidente	severe pain near the wrist	several pain near the waist	Se modifica la localización anatómica : muñeca → cintura/zona abdominal, además de perderse la intensidad "severe".
audio01 — Dolor torácico	severe chest pain	several chest pain	Se altera la descripción de intensidad del dolor: "severo" pasa a interpretarse como "varios".
audio01 — Dolor torácico	no known allergies	no knowledge	Se pierde la información explícita sobre alergias conocidas .

Tabla H1. Ejemplos observados de errores de reconocimiento que modifican información semánticamente relevante en la traducción posterior.

Estos casos muestran que WER y chrF permiten cuantificar el rendimiento global, pero no representan por sí solos la importancia semántica de un error específico.

CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR

Anexo I. Archivos y scripts entregados

En este anexo presentamos los principales scripts, referencias y archivos de resultados entregados para documentar y reproducir los experimentos.

Archivo	Función
asr_pipeline.jl	Ejecuta Whisper y gestiona la transcripción de los audios.
benchmark_asr.jl	Ejecuta el benchmark ASR y calcula WER, CER y RTF.
translate_pipeline.jl	Ejecuta la etapa ASR→LLM y gestiona las traducciones.
benchmark_translate.jl	Evalúa la traducción mediante chrF.
benchmark_weight_error.py	Analiza el error de representación de los pesos cuantizados.
groundtruth.txt	Transcripciones inglesas de referencia utilizadas para WER y CER.
groundtruth_es.txt	Traducciones españolas independientes utilizadas como referencia para chrF.
asr_per_audio.csv / asr_summary.csv	Resultados detallados y resumen del experimento ASR.
translation_per_audio.csv / translation_summary.csv	Resultados detallados y resumen de traducción.
r3_per_audio.csv / r3_summary.csv	Resultados de propagación de error ASR→LLM.
quantization_error_summary.csv / quantization_error_by_tensor.csv	Resultados del análisis de error de cuantización de pesos.
Audios WAV	Corpus de 10 segmentos clínicos utilizado en los experimentos.

Tabla I1. Principales archivos entregados para documentar y reproducir los experimentos de reconocimiento, traducción, cuantización y propagación del error.