

ESTUDIO DE CASO –5 %
ESTUDIO DE CASO
“CUANTIZACIÓN Y PROPAGACIÓN DEL ERROR EN
TRADUCCIÓN EN TIEMPO REAL”

Nombre de los Integrantes	
Fecha de Entrega	26 de Agosto
Carrera	Ingeniería Civil Informática
Académico	Sergio Hernández
Actividad Curricular	Computación Numérica (INF-321)

PUNTAJE MÁXIMO	80	PUNTAJE DE CORTE	48	PUNTAJE OBTENIDO		CALIFICACIÓN	
-----------------------	----	-------------------------	----	-------------------------	--	---------------------	--

Resultados de Aprendizajes Evaluados:	Comprender la naturaleza de los errores numéricos en dispositivos de cálculo, considerando la investigación como estrategia de identificación de problemas.
Indicadores de Evaluación:	■ Aplica correctamente la aritmética de punto flotante. ■ Determina errores de propagación en operaciones. ■ Maneja dispositivos de cálculo, entendiendo la representación y operatoria de los números. ■ Utiliza software de apoyo. ■ Utiliza la investigación en la determinación de problemas de aplicación.

INSTRUCCIONES PARA EL DESARROLLO DE LA EVALUACIÓN

Para el desarrollo de su evaluación debe considerar lo siguiente:

1. El trabajo debe presentarse en forma grupal e individual.
2. Todo experimento debe ser reproducible: indicar hardware (CPU/GPU, sistema operativo), versión de `whisper.cpp` (*commit hash*), versión de Ollama, nombre y *tag* exacto de cada modelo, número de hilos, semillas y parámetros de decodificación utilizados. Los resultados que no puedan reproducirse no reciben puntaje.
3. Todo valor numérico reportado debe indicar el número de cifras significativas empleadas y, cuando corresponda, si se trata de un error absoluto o relativo. No se aceptan cifras sin unidad ni sin definición del error utilizado.
4. Etiquetar y titular figuras y tablas. Las figuras, por ejemplo, deben llamarse Figura 1, Figura 2, etc. (o incluir el número de sección, como Figura 1.3 para la tercera figura de la sección 1) con un breve título descriptivo para cada una. Luego, podrás consultarlos fácilmente en el texto. Hacer referencia a figuras y tablas por su nombre evita cualquier ambigüedad que algo como la figura de arriba pueda introducir.
5. Las figuras deben estar centradas en la página con un título centrado debajo de ellas. Poner el título en cursiva ayuda a que se destaque visualmente del resto del texto. Considere el tamaño de cada figura: no deben ser tan pequeñas que los detalles sean difíciles de discernir, ni deben ser más grandes de lo necesario para ver claramente todos los detalles, ya que eso desperdicia espacio en la página.
6. Al incluir código o salida de terminal (transcripción de shell) en un documento, formateéelo con una fuente monoespaciada. Consolas, DejaVu Sans Mono y Menlo son buenas opciones que se encuentran comúnmente disponibles.
7. No incluya código, gráficos, tablas ni una transcripción del shell como captura de pantalla del código de una página web, editor de texto o terminal. Hacer esto produce una imagen rasterizada del texto que será de baja resolución, pixelada, imposible de resaltar y copiar, e inaccesible para cualquiera que utilice un software de lectura de pantalla.

Restricciones

Se aplicará artículo 67° del reglamento del estudiante, el cual indica que, en caso de sorprender copia parcial o exacta, ya sea entre compañeros o reproducidos de algún medio, lo cual implica un 1,0 para todos los involucrados. Si hay algún requerimiento sin contestar, y en la rúbrica no se puede observar, no aplica puntaje. Los experimentos deben ejecutarse localmente (*on-device*): no se acepta el uso de servicios de transcripción o traducción en la nube (APIs comerciales) para producir los resultados medidos, ya que el objetivo es controlar la representación numérica de los modelos. El corpus de audio debe ser de libre uso o de grabación propia con consentimiento de los hablantes; adjuntar la referencia de la fuente.

DESCRIPCIÓN DEL CASO Y DE LAS PREGUNTAS O REQUERIMIENTOS A SER RESUELTOS

Caso:

Un centro de atención de urgencia de la Región del Maule desea implementar un sistema de **traducción en tiempo real** que permita atender a pacientes que no hablan español (por ejemplo, creole haitiano o inglés). Por razones de confidencialidad de los datos clínicos, el sistema debe ejecutarse **completamente en el dispositivo local** (un computador de escritorio sin GPU dedicada), con una latencia inferior al tiempo real (*real-time factor* < 1). La arquitectura propuesta es una **cascada** de dos etapas:

1. **Reconocimiento automático del habla** con `whisper.cpp` (<https://github.com/ggml-org/whisper.cpp>), implementación en C/C++ del modelo Whisper sobre la biblioteca `ggml`.
2. **Traducción y normalización del texto** con un modelo de lenguaje local servido mediante **Ollama** (<https://ollama.com>).

El equipo disponible no tiene memoria suficiente para ejecutar ambos modelos en precisión completa, por lo que se recurre a la **cuantización**: los pesos, originalmente almacenados en punto flotante IEEE-754 de 32 bits (binary32, con $p = 24$ bits de mantisa y unidad de redondeo $u = 2^{-24} \approx 5,96 \times 10^{-8}$), se convierten a formatos de menor ancho de palabra (F16, Q8_0, Q5_1, Q4_0, Q4_K_M, entre otros). En los esquemas `ggml/gguf` los pesos se agrupan en bloques de 32 valores que comparten un factor de escala d almacenado en punto flotante de 16 bits, de modo que cada peso se reconstruye como

$$\tilde{w}_i = d q_i + m, \quad q_i \in \mathbb{Z} \cap [q_{\min}, q_{\max}],$$

lo que introduce un error de representación $\varepsilon_i = \tilde{w}_i - w_i$ acotado por medio paso de cuantización, $|\varepsilon_i| \leq d/2$. Cada capa del modelo evalúa productos punto de longitud n (típicamente $n \geq 512$). Bajo el modelo estándar de aritmética de punto flotante, $\text{fl}(a \circ b) = (a \circ b)(1 + \delta)$ con $|\delta| \leq u$, el error acumulado de un producto punto satisface la cota clásica

$$\left| \text{fl}\left(\sum_{i=1}^n a_i b_i\right) - \sum_{i=1}^n a_i b_i \right| \leq \gamma_n \sum_{i=1}^n |a_i| |b_i|, \quad \gamma_n = \frac{nu}{1 - nu},$$

a lo que se suma el error de cuantización de los propios coeficientes. Estos errores no permanecen aislados: se propagan a través de decenas de capas, atraviesan operaciones sensibles como `softmax` y `logsumexp` (donde puede aparecer *cancelación catastrófica* al restar cantidades cercanas), y luego se realimentan en la **decodificación autorregresiva**, en la que cada token generado condiciona a los siguientes. Finalmente, la salida de la etapa 1 es la entrada de la etapa 2, por lo que la cascada compone dos operadores y, en primera aproximación, sus números de condición se multiplican, $\kappa_{\text{total}} \approx \kappa_{\text{LLM}} \cdot \kappa_{\text{ASR}}$.

Un detalle adicional relevante: la suma en punto flotante **no es asociativa**, por lo que cambiar el número de hilos de ejecución (-t en `whisper.cpp`) altera el orden de las reducciones y puede producir salidas distintas para la misma entrada y el mismo modelo.

DESCRIPCIÓN DEL CASO Y DE LAS PREGUNTAS O REQUERIMIENTOS A SER RESUELTOS

Para que el equipo pueda cuantificar, y no solo describir, el efecto de estos errores numéricos sobre la calidad del resultado final, se emplean tres métricas estándar de evaluación: la **Tasa de Error de Palabra** (*Word Error Rate, WER*) y la **Tasa de Error de Carácter** (*Character Error Rate, CER*), que cuantifican la distancia de edición (inserciones, sustituciones y eliminaciones) entre la transcripción generada por `whisper.cpp` y la transcripción de referencia, normalizada por la longitud de esta última; y el **BLEU** (*Bilingual Evaluation Understudy*), que evalúa la calidad de la traducción producida por el modelo servido en Ollama mediante la coincidencia de n -gramas con una o más traducciones de referencia. Estas métricas permiten trazar, para cada formato de cuantización, una curva de degradación de la calidad y así identificar el punto en que el error numérico deja de ser despreciable desde el punto de vista clínico.

El centro de salud le solicita a su equipo un informe técnico que responda: *¿cuánta precisión numérica se puede sacrificar antes de que la traducción deje de ser clínicamente confiable?*

REQUERIMIENTOS: Cada grupo (2 a 3 integrantes) debe diseñar y ejecutar un experimento numérico que cuantifique el efecto de la cuantización y la propagación del error en la cascada ASR → LLM, y comunicar sus resultados en un informe y una presentación.

REQUERIMIENTOS ESPECÍFICOS

R1. Representación numérica y aritmética de punto flotante.

- a) Compilar `whisper.cpp` y descargar un modelo (se sugiere `base` o `small`) en formato F32/F16. Generar al menos tres versiones cuantizadas con la herramienta `quantize` incluida en el repositorio (por ejemplo Q8_0, Q5_1, Q4_0).
- b) Para cada formato, reportar: tamaño en disco, memoria RAM utilizada, bits efectivos por peso (incluyendo el costo amortizado del factor de escala por bloque) y el paso de cuantización d .

R2. Efecto de la cuantización sobre la precisión de la transcripción y la traducción.

- a) Construir un corpus de al menos 10 segmentos de audio (15–30 s) con transcripción y traducción de referencia (grabación propia o corpus abierto tipo Common Voice o LibriSpeech).
- b) Ejecutar la transcripción y la traducción con cada formato del modelo, midiendo **WER** y **CER** para la transcripción, y **BLEU** o **chrF** para la traducción, además del *real-time factor* y el consumo de memoria.
- c) Graficar la curva de precisión *versus* bits por peso e identificar el punto de quiebre a partir del cual el error crece de manera no lineal. Discutir el compromiso precisión–memoria–latencia usando lenguaje de análisis de error (error absoluto y relativo, error de truncamiento frente a error de redondeo).

R3. Propagación del error en la cascada con Ollama.

- a) Servir un mismo modelo de lenguaje en Ollama con al menos dos cuantizaciones distintas (por ejemplo `q4_0` y `q8_0` de un modelo de 7–8B) y usarlo para traducir, fijando `temperature = 0` para aislar el efecto numérico del efecto del muestreo.
- b) Separar las fuentes de error mediante tres condiciones experimentales: (i) traducir la **transcripción de referencia** (error del LLM aislado); (ii) traducir la salida del ASR en alta precisión; (iii) traducir la salida del ASR cuantizado (error compuesto). Reportar los tres errores en una misma tabla.

R4. Investigación e identificación del problema.

- a) Formular una recomendación técnica al centro de salud: qué formato usar, con qué margen de error esperado y qué riesgos residuales existen para un uso clínico.

FORMATO DE ENTREGA

Formato:

La entrega consta de un **informe breve** (máximo 6 páginas, sin contar anexos) y una **presentación grupal de 10 minutos**, con la siguiente estructura:

- Introducción y planteamiento del problema numérico (Grupal).
- Marco teórico: representación en punto flotante, cuantización y propagación del error (Grupal).
- Diseño experimental, software utilizado y resultados en tablas y figuras (Grupal).
- Análisis de la propagación del error en la cascada y conclusiones (Grupal).
- Revisión crítica de un artículo o documentación técnica (Individual).

Una vez finalizada la presentación grupal, cada integrante debe presentar su artículo (1 diapositiva) demostrando capacidad de análisis, síntesis, evaluación y aplicación del conocimiento. En total cada grupo dispone de 20 minutos para la presentación grupal e individual.

Se debe adjuntar además un repositorio o carpeta comprimida con los *scripts* utilizados (Julia, Python u Octave), los archivos de audio o su referencia, y las salidas crudas de cada corrida. Se sugiere organizar los resultados en tablas del siguiente tipo:

Formato	Bits/peso	Memoria (MB)	WER (%)	chrF	RTF
F32	32				
F16	16				
Q8_0					
Q5_1					
Q4_0					

Condición experimental	Error de entrada	Error de salida	κ empírico
Referencia $\rightarrow$ LLM	0		
ASR alta precisión $\rightarrow$ LLM			
ASR cuantizado $\rightarrow$ LLM			

RÚBRICA

Indicadores	Valores				Observaciones
	Destacado (10 pts)	Competente (7 pts)	Básico (5 pts)	En Desarrollo (2 pts)	
Presentación y formato (Grupal)	Informe y presentación impecables, bien organizados, dentro del tiempo, con tablas y figuras rotuladas y sin errores tipográficos.	Buena presentación, mayormente organizada, con pocos errores tipográficos o de rotulación.	Presentación aceptable, pero con errores tipográficos o de organización.	Presentación desorganizada o con numerosos errores.	1
Representación numérica y punto flotante (Grupal)	Deduce correctamente las cotas de error de cada formato, las verifica experimentalmente y las contrasta con la unidad de redondeo de <code>binary32/binary16</code> .	Deduce y verifica las cotas de error de los formatos, con contraste parcial.	Describe los formatos y reporta tamaños, pero sin deducir ni verificar cotas de error.	No distingue los formatos ni aplica la aritmética de punto flotante.	2
Diseño experimental y uso de software (Grupal)	Experimento reproducible y bien controlado; usa <code>whisper.cpp</code> y Ollama con métricas apropiadas, corpus adecuado y <i>scripts</i> documentados.	Experimento correcto y reproducible, con métricas apropiadas pero controles o documentación parciales.	Ejecuta las herramientas y reporta resultados, sin control de variables ni reproducibilidad.	No logra ejecutar los experimentos o los resultados no son verificables.	3
Manejo de dispositivos de cálculo (Grupal)	Reporta memoria, <i>real-time factor</i> y bits por peso de cada formato, y evidencia el efecto del número de hilos y del orden de las reducciones sobre la salida.	Reporta memoria y latencia por formato y verifica la variabilidad al cambiar hilos o semilla.	Reporta memoria o latencia sin analizar su relación con la representación numérica.	No caracteriza el dispositivo ni el costo de cada formato.	4
Análisis de propagación del error (Grupal)	Separa las fuentes de error, estima el factor de amplificación, lo interpreta en términos de condicionamiento y contrasta con las cotas teóricas.	Separa las fuentes de error y estima la amplificación, con interpretación parcial.	Compara errores entre formatos sin descomponer ni cuantificar la propagación.	Análisis del error ausente o incorrecto.	5
Investigación y evaluación crítica (Individual)	Selecciona una fuente pertinente, evalúa críticamente sus fortalezas y debilidades y la vincula explícitamente con los resultados obtenidos.	Evalúa críticamente la fuente y la relaciona con el caso.	Resume la fuente e identifica alguna fortaleza o debilidad.	Revisión ausente, superficial o sin relación con el caso.	6

Indicadores	Valores				Observaciones
	Destacado (10 pts)	Competente (7 pts)	Básico (5 pts)	En Desarrollo (2 pts)	
Claridad y coherencia (Individual)	Presenta las ideas de manera clara, concisa y lógica, con lenguaje técnico apropiado y uso correcto de cifras significativas.	Ideas claras y bien organizadas, con lenguaje técnico apropiado.	Utiliza un lenguaje apropiado, con exposición poco estructurada.	Exposición confusa o insuficiente.	7
Conclusiones y recomendación técnica (Individual)	Conclusión fundamentada en la evidencia numérica, con recomendación explícita, margen de error esperado y riesgos residuales del uso clínico.	Conclusión clara y bien relacionada con los objetivos, con recomendación fundamentada.	Conclusión presente pero poco clara o insuficientemente relacionada con los resultados.	Conclusión ausente o irrelevante.	8
PUNTAJE TOTAL (máximo 80 puntos)					

ESCALA DE NOTAS

Puntaje máximo: 80 puntos. Puntaje de corte (nota 4,0): 48 puntos, correspondiente a un 60 % de exigencia.

Puntaje	Nota	Puntaje	Nota	Puntaje	Nota	Puntaje	Nota
0	1,0	21	2,3	42	3,6	63	5,4
1	1,1	22	2,4	43	3,7	64	5,5
2	1,1	23	2,4	44	3,8	65	5,6
3	1,2	24	2,5	45	3,8	66	5,7
4	1,3	25	2,6	46	3,9	67	5,8
5	1,3	26	2,6	47	3,9	68	5,9
6	1,4	27	2,7	48	4,0	69	6,0
7	1,4	28	2,8	49	4,1	70	6,1
8	1,5	29	2,8	50	4,2	71	6,2
9	1,6	30	2,9	51	4,3	72	6,3
10	1,6	31	2,9	52	4,4	73	6,3
11	1,7	32	3,0	53	4,5	74	6,4
12	1,8	33	3,1	54	4,6	75	6,5
13	1,8	34	3,1	55	4,7	76	6,6
14	1,9	35	3,2	56	4,8	77	6,7
15	1,9	36	3,3	57	4,8	78	6,8
16	2,0	37	3,3	58	4,9	79	6,9
17	2,1	38	3,4	59	5,0	80	7,0
18	2,1	39	3,4	60	5,1		
19	2,2	40	3,5	61	5,2		
20	2,3	41	3,6	62	5,3		